Reporte Técnico

Data-Driven Growth Analysis: Olist E-Commerce

Data Intelligence Pipeline & Demand Forecasting

Aland Rodríguez Martín del Campo
Physicist — Data Analyst

1 de abril de 2026

LinkedIn /in/alandrodmar
GitHub @AlandRodMar

Índice

1. Introducción **2**

2. Fase I: Diagnóstico y Análisis Histórico **2**

2.1. Creación de la base de datos 2
2.2. Obtención de datos 4
2.3. Evolución histórica 5
2.4. Correlacion Ingresos vs Pedidos 6
2.5. Ticket Mensual Promedio 8
2.5.1. *Lagunas en Registros (2016)* 9
2.6. Información sobre los pedidos 9
2.7. Estacionalidad semanal 10
2.8. Estacionalidad mensual 12

3. Conclusiones de la Fase I **13**

Resumen

Este documento detalla la Fase I del análisis y pronóstico de demanda del e-commerce brasileño *Olist*, centrada en la creación de base de datos, extracción y limpieza de los registros necesarios, así como un diagnóstivo descriptivo de la serie de tiempo correspondiente a los pedidos e ingresos diarios. Se identifica la tendencia, los patrones de estacionalidad semanal y las estadísticas básicas como el ticket promedio diario.

La Fase II estará enfocada en el pronóstico de la demanda.

1 Introducción

El presente reporte describe el pipeline de datos utilizado para desarrollar la inteligencia de datos del e-commerce brasileño *Olist*.

Se explica de dónde se han obtenido los datos y cómo se han trabajado a manera de crear una base de datos usando MySQL, previo a su análisis cuantitativo por medio de Python, en donde se ha obtenido un seguimiento del histórico de registros, cuyos datos se han transformado en información que puede utilizarse para optimizar la logística semanal dentro de la empresa.

La segunda fase se centrará en realizar un pronóstico de la demanda con base en los hallazgos obtenidos durante la primer fase.

2 Fase I: Diagnóstico y Análisis Histórico

En esta primera fase se analizarán los datos pasados Olist con la finalidad de cuantificar el estado actual de la empresa y destacar los patrones que se encuentren con base a mirar el pasado histórico.

Se busca hallar la tendencia de las ventas y cantidad de pedidos, así como valores promedio de los tickets mensuales o demanda por día de la semana.

2.1. Creación de la base de datos

En esta primera parte se hace el análisis de los datos del marketplace brasileño *Olist*, disponible en Kaggle, sin embargo, no se hace uso de ellos a través de los archivos csv directamente, sino que se simula un entorno de trabajo en el que dichos datos puedan ser actualizables mediante la creación de una base de datos en MySQL automatizada con Python haciendo uso de `create_engine`, `os`, `load_dotenv` y `pandas`:

```
        load_dotenv()

        user = os.getenv("DB_USER")
        password = os.getenv("DB_PASSWORD")
        host = os.getenv("DB_HOST")
```

```python
        database = "olist_project"

        engine = create_engine(f"mysql+mysqlconnector://{user}:{password}@{host}/{database}")

        data_path = "Ruta_de_los_CSV_de_Olist"
        for file in os.listdir(data_path):
            if file.endswith(".csv"):
                table_name = file.replace(".csv", "").replace("_dataset", "")

                try:
                    temp_df = pd.read_csv(os.path.join(data_path, file))

                    temp_df.columns = [c.lower().replace(' ', '_').replace('.', '_') for c in temp_df.columns]

                    print(f"Cargando {table_name}...")
                    temp_df.to_sql(table_name, con=engine, if_exists='replace', index=False, chunksize=1000)
                    print(f"Tabla '{table_name}' cargada con éxito.")

                except Exception as e:
                    print(f"Error al cargar {table_name}: {e}")
                    engine.dispose()
                    engine = create_engine(f"mysql+mysqlconnector://{user}:{password}@{host}/{database}")
```

Si bien podría haberse hecho uso directo de los archivos csv desde Python y extraer los datos requeridos, se ha optado por la creación de la base de datos en MySQL con el fin de simular un entorno de trabajo empresarial y la escalabilidad propia de una base de este tipo.

2.2. Obtención de datos

Una vez creada la base de datos, se realizan las consultas adecuadas para obtener la cantidad de pedidos e ingresos diarios en MySQL Workbench de manera que se asegure la unión correcta entre tablas para evitar registros duplicados y pedidos cancelados o no entregados:

```sql
SELECT
    DATE(O.order_purchase_timestamp) AS fecha,
    SUM(OI.price) AS ingresos_diarios,
    COUNT(DISTINCT O.order_id) AS cantidad_pedidos
FROM olist_orders AS O
JOIN olist_order_items AS OI ON O.order_id = OI.order_id
WHERE O.order_status = 'delivered'
GROUP BY fecha
ORDER BY fecha;
```

En este punto, la base de datos ya ha sido creada y conectada a Python. Se obtendrán los datos de las ventas y cantidad de pedidos diarias para responder a las preguntas:

- **Visibilidad histórica:** ¿Cómo se ven la evolución de las ventas diarias desde el inicio de las operaciones de la empresa?
- **Calidad en las entregas:** ¿Cuántos de los pedidos realmente llegaron al cliente? (Esto es importante ya que la fase de pronóstico no debe estar basada en datos que contengan cancelaciones, sino en entregas completadas).
- **Identificación de patrones estacionales:** ¿Existen ciclos recurrentes (picos de demanda semanales o mensuales) que se deberían informar a los equipos de ventas y logística?

Nota: Se ha optado por considerar únicamente el precio de venta neto de cada producto, omitiendo el costo del envío, esto es debido a que no se sabe con certeza si los envíos son gestionados directamente por Olist o por paqueterías externas, por lo que no puede asegurarse que el monto de los envíos sean ingresos para la empresa. Si se tomasen en cuenta, podrían sobreestimarse los ingresos, lo que conllevaría a una toma de decisiones con alta incertidumbre. Además, se ha realizado la consulta a la base de datos de manera que la relación entre tablas sea adecuada, a manera de que no se dupliquen transacciones que podrían sesgar los ingresos y cantidad de pedidos.

2.3. Evolución histórica

Con los datos obtenidos a través de la consulta a MySQL, se crea una visualización histórica de su evolución para identificar la tendencia de las ventas mediante medias móviles en la serie de tiempo. Esto se puede ver en la Fig. (1).

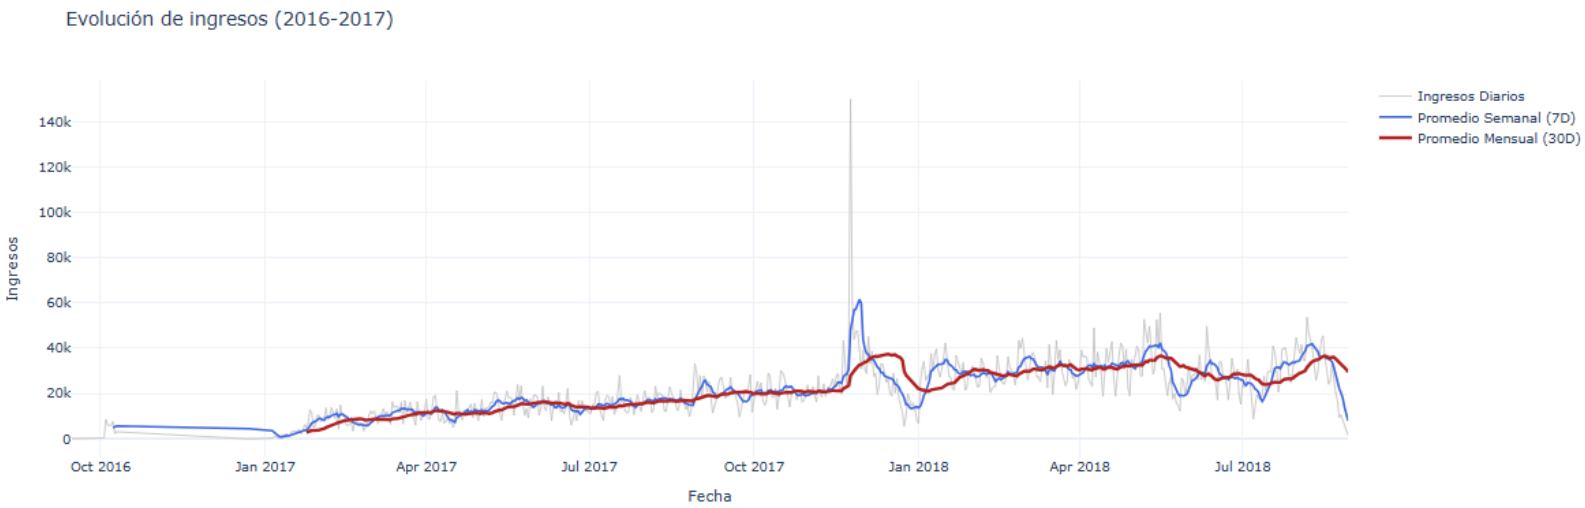

Figura 1: Serie de tiempo entre 2016 y 2017 de la evolución de los ingresos diarios en crudo y medias móviles semanal (7 días) y mensual (30 días).

De la Fig. (1) puede decirse que:

- **Tendencia alcista:** A pesar de que existe fluctuación en los ingresos diarios, la tendencia a lo largo de estos dos años ha sido, en general, alcista. Los ingresos han aumentado con el paso de los meses.

- **"Laguna" de ventas:** Posteriormente se revisará qué sucedió entre Octubre y Diciembre del 2016 ya que es un periodo de ingresos sumamente bajos, casi nulos.

  Por otra parte, debe analizarse qué ha sucedido durante el último mes de la serie de tiempo, pues los ingresos han roto la tendencia alcista de una manera muy agresiva, tendiendo a la baja.

- **El mejor día:** La mayor cantidad de ingresos de todos los días (El "pico" que se observa durante Noviembre del 2017 y que llega hasta ingresos mayores a $140k) fue durante el *Black Friday* del 2017 (24 de Noviembre). Casi 7 veces más ingresos que cualquier otro día. Esto se debió al fuerte impacto que tuvo este evento, pues la cantidad de pedidos fue de 1345.

Al realizar una descripción estadística de estos datos históricos se ha encontrado que:

- El total de ingresos es de más de \$13.22 millones.
- El promedio de ingresos diarios es de $\approx$ \$21600.
- La cantidad promedio de pedidos diarios es de 180.

El hecho de que la tendencia en los ingresos diarios sea creciente, conlleva a otra pregunta: ¿Se están vendiendo más productos cada día o se están vendiendo productos más caros?

Para responder a esta pregunta es adecuado hacer una comparación entre los ingresos diarios y el volúmen de pedidos, así como obtener la evolución del ticket mensual promedio.

2.4. Correlacion Ingresos vs Pedidos

Si se grafican a la par, la cantidad de pedidos diarios y los ingresos, se obtiene la Fig. (2).

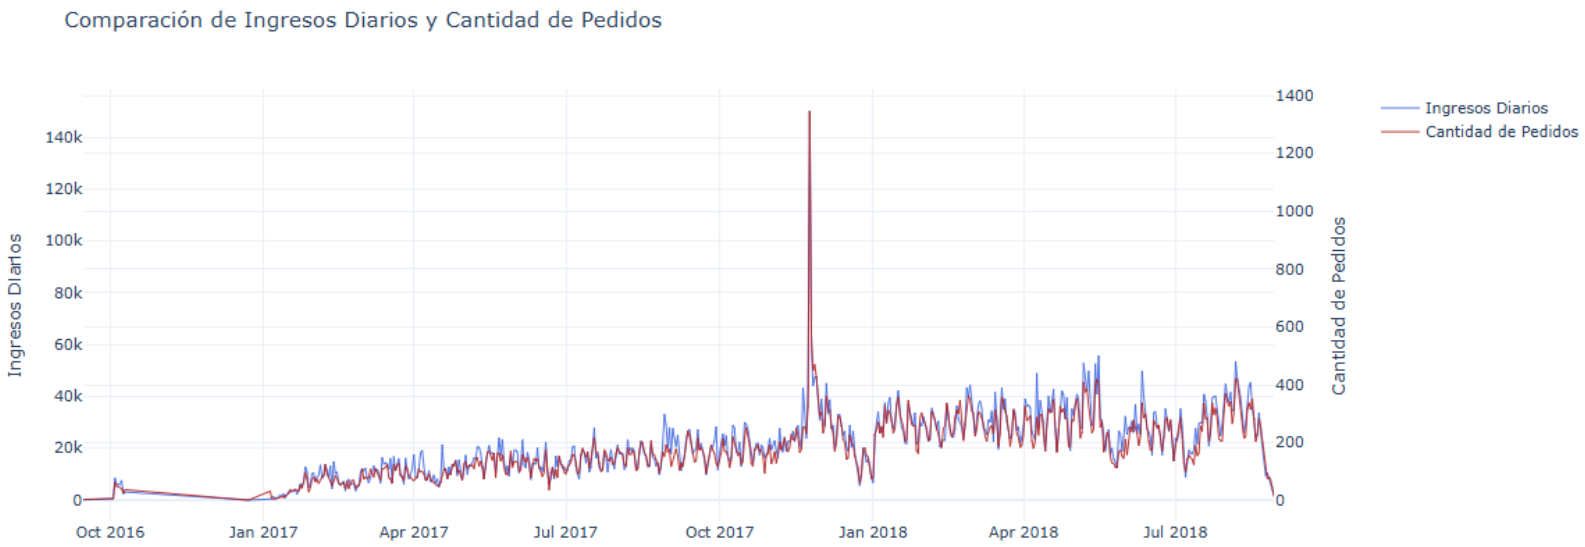

Figura 2: Series de tiempo entre 2016 y 2017 de la evolución de los ingresos diarios y la cantidad de pedidos diarios.

En esta gráfica puede observarse que ambas variables tienen una correlación muy alta, lo cual puede cuantificarse.

Primero que nada, se debe descubrir si los datos tienen una distribución normal o no y con base en eso calcular su coeficiente de correlación. En particular, para este caso, se usará un gráfico Cuantil-Cuantil (Q-Q Plot) respaldado por el valor de R^2. Además, será complementado con el test de Shapiro-Wilk, cuya hhipótesis nula (H_0) sugiere que la distribución es normal.

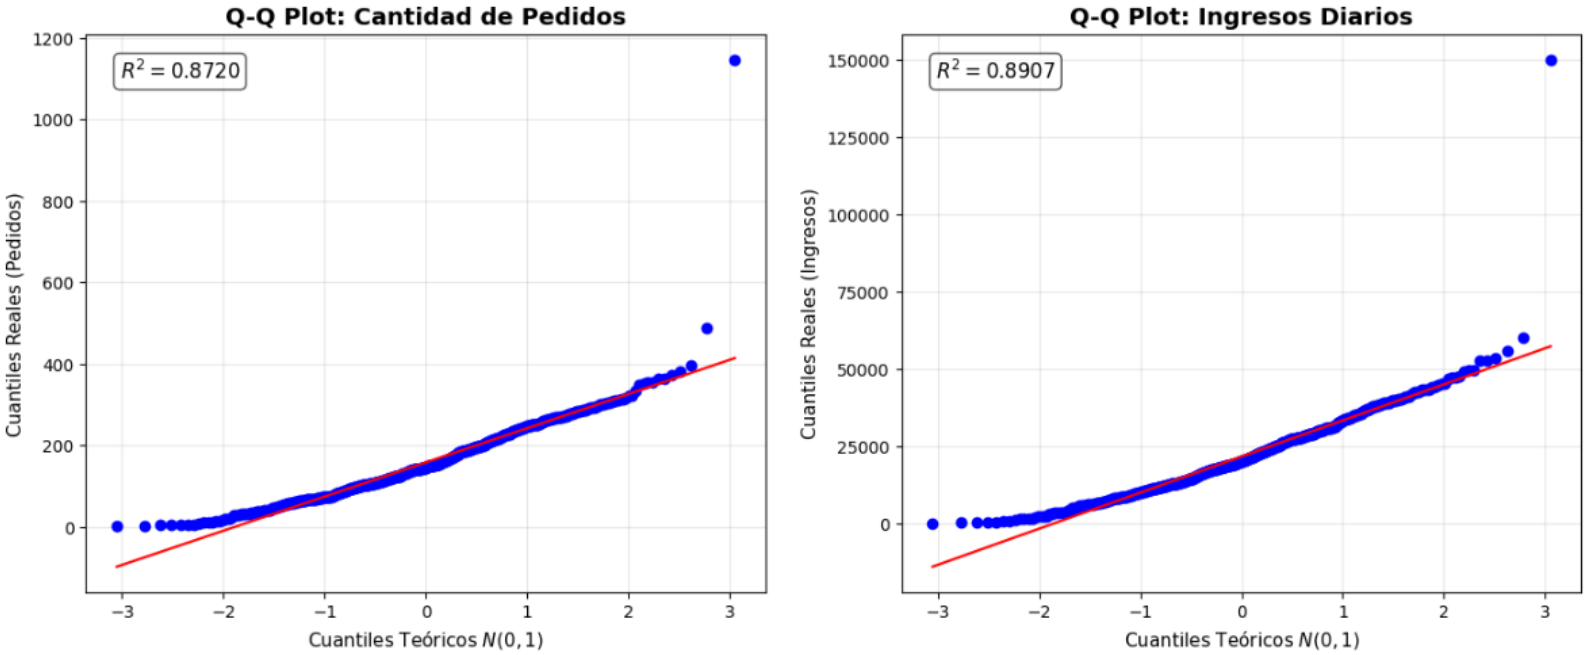

Figura 3: Gráficos Cuantil-Cuantil (Q-Q Plots) de los pedidos e ingresos diarios.

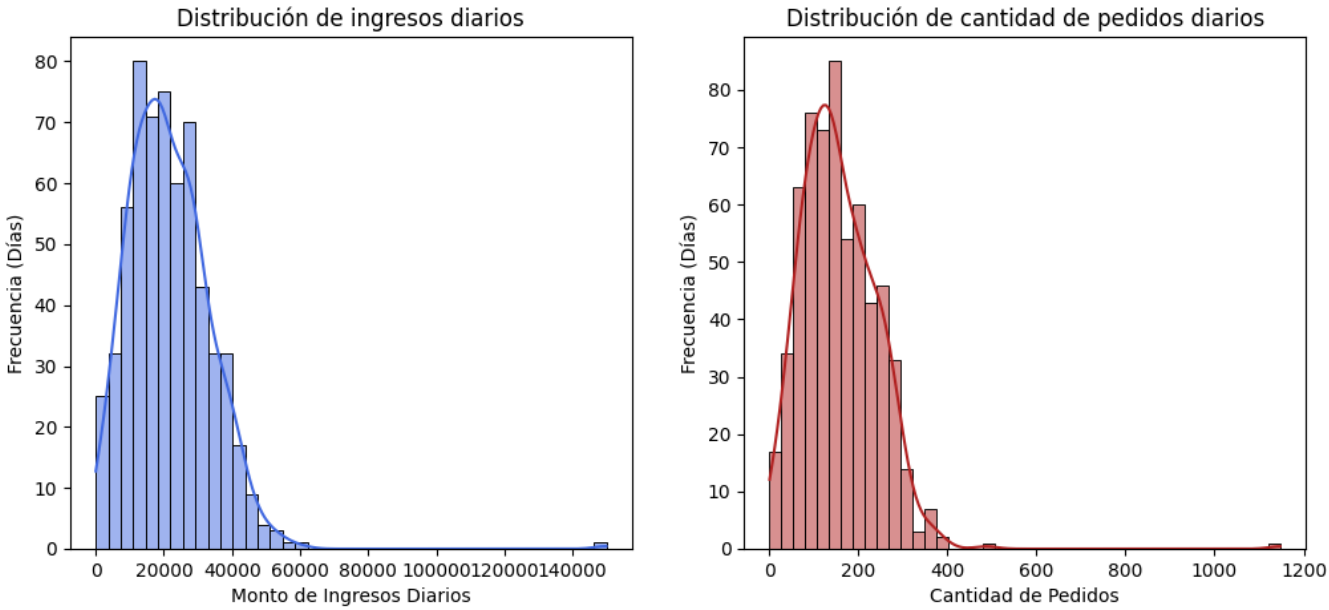

Figura 4: Histogramas de la distribución de los ingresos y cantidad de pedidos diarios.

Las gráficas de la Fig. (3) muestran claramente que ninguna de las dos variables tiene una distribución normal (presentan una función de distribución de probabilidad con colas pesadas), lo cual era de esperarse debido a que tienen un límite inferior del lado izquierdo (no pueden ser menores que 0). Esto se comprueba cuantitativamente mediante el valor de R^2 para cada una, el cual resulta ser menor que 0.95. De manera adicional, los histogramas de la Fig. (4) sugieren que, efectivamente, no se trata de una distribución normal, lo cual se confirma con los valores $p \ll 0.05$ obtenidos, por lo que no puede usarse el coeficiente de correlación de Pearson. Entonces se recurre a calcular el coeficiente de correlación de Spearman, que resulta ser de ≈ 0.9610, lo cual confirma la alta correlación entre los ingresos y la cantidad de pedidos.

2.5. Ticket Mensual Promedio

Ya se sabe que *un aumento en los ingresos va acompañado por un mayor volúmen de pedidos*, por lo que ahora para responder si el incremento en los ingresos se debe, precisamente, a un incremento en los pedidos, debe estudiarse el ticket promedio mensual.

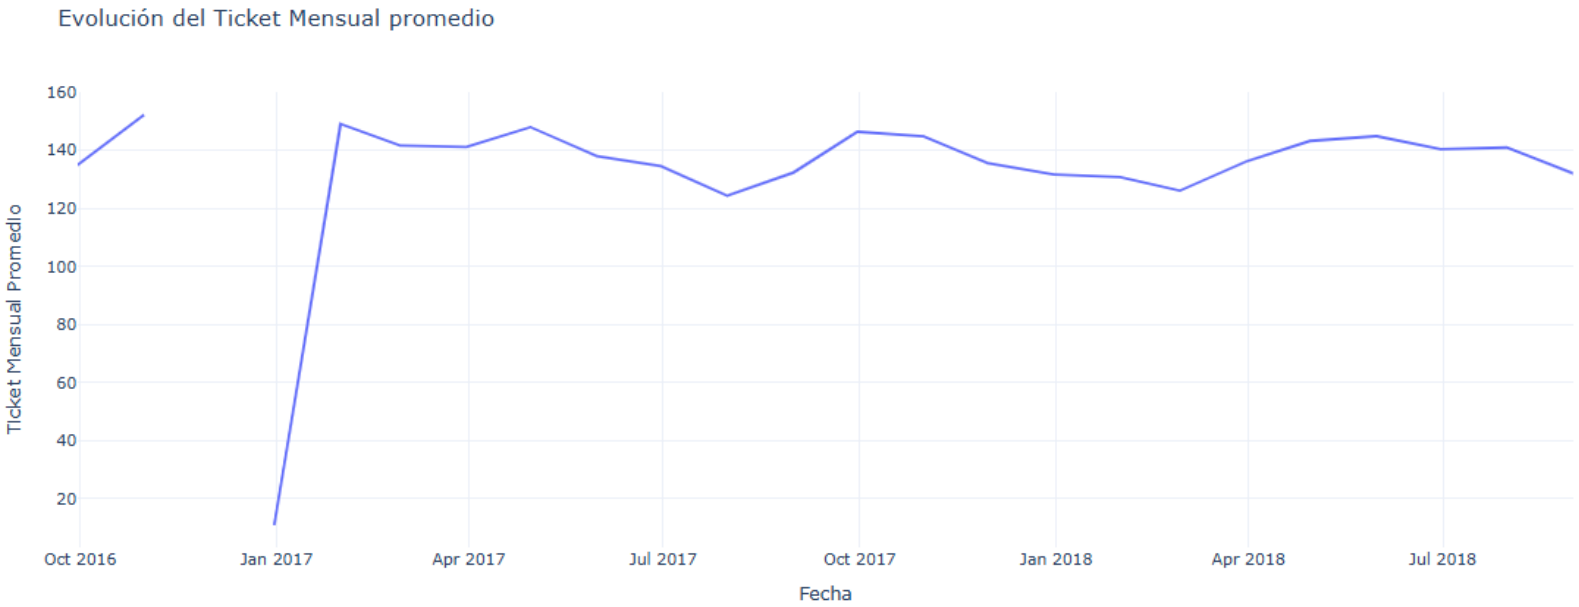

Figura 5: Evolución histórica del ticket promedio.

La Fig. (5) muestra que la evolución del ticket promedio es relativamente constante desde Enero del 2017, oscilando en torno a \$137.04. Además, puede verse una brecha entre Noviembre y Diciembre del 2016. Debe revisarse qué sucedió con los datos en ese periodo.

Que el ticket mensual promedio sea casi constante refuerza el hecho de que el incremento en los ingresos diarios se debe al volúmen de pedidos realizados y no necesariamente al alza de los precios o venta de productos más caros. En palabras simples: Si cada ticket es similar, entonces la única forma de que los ingresos aumenten es porque hay más tickets.

2.5.1. *Lagunas en Registros (2016)*

La ausencia de datos se da entre Septiembre y Diciembre y sugiere algunos caminos:

- Considerar únicamente los datos del periodo en el que son constantes (omitir todos los registros anteriores a Enero del 2016).
- Considerar su ausencia durante la interpretación de los resultados.
- No es muy recomendable sustituir esos valores por ceros (sesgarían demasiado los promedios de esos meses) ni rellenarlos con valores cercanos al promedio (existe un riesgo de sesgar, nuevamente, los resultados de esos meses).

2.6. Información sobre los pedidos

Un análisis a los datos existentes, muestra que, en el último mes (Agosto 2017) no falta ningún dato, sin embargo, esto tendría que comunicarse urgentemente al equipo de ventas y logística para estudiar distintos criterios que podrían estar provocando esta baja en los ingresos. Por su parte, analizando la "laguna" de datos al inicio, se observa lo siguiente:

- **Septiembe 2016:** El único registro es del día 15 de Septiembre.
- **Octubre 2016:** Solamente se tienen registros desde el día 3 hasta el 10 de Octubre.
- **Diciembre 2016:** Se tiene únicamente un registro, el del día 23 de Diciembre.

Por otra parte, la respuesta a *¿Cuántos de los pedidos realmente llegaron al cliente?* es dada gracias a la forma en la que se consultaron los datos y se construyó el dataframe (seleccionando únicamente aquellos pedidos cuyo estado es *delivered*).

Se han entregado 96478 pedidos (97.02 % del total) y se han cancelado 625 (0.63 %). Por otra parte, el porcentaje de pedidos que se encuentran en proceso es de 1.11 %, mientras que aquellos carentes de información representan el 1.24 % restante.

2.7. Estacionalidad semanal

Con la finalidad de hallar información relacionada con la logística de la empresa, se revisa la cantidad de pedidos promedio por día de la semana, visibles en la Fig. (6).

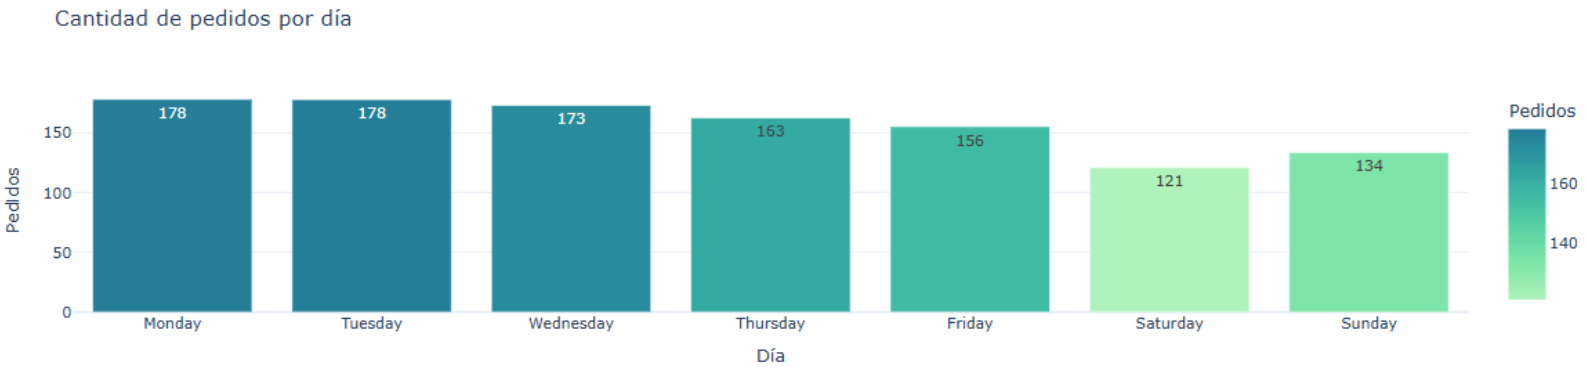

Figura 6: Cantidad promedio de pedidos realizados por día de la semana.

Estos datos muestran que la cantidad de pedidos va disminuyendo conforme se aproxima el fin de semana, siendo los Sábados cuando menos pedidos se hacen (casi 32 % menos que los Lunes o Martes, los que, aparentemente, son los días en que hay más pedidos). Sin embargo, una sospecha no es suficiente para afirmarlo, para validar la observación descriptiva, y confirmar si esta ciclicidad es una propiedad de los datos bajo estudio, se usará la función de autocorrelación (ACF), mientras que la función de autocorrelación parcial (PACF) permitirá aislar la influencia directa de los retardos (lags) previos sobre la demanda actual.

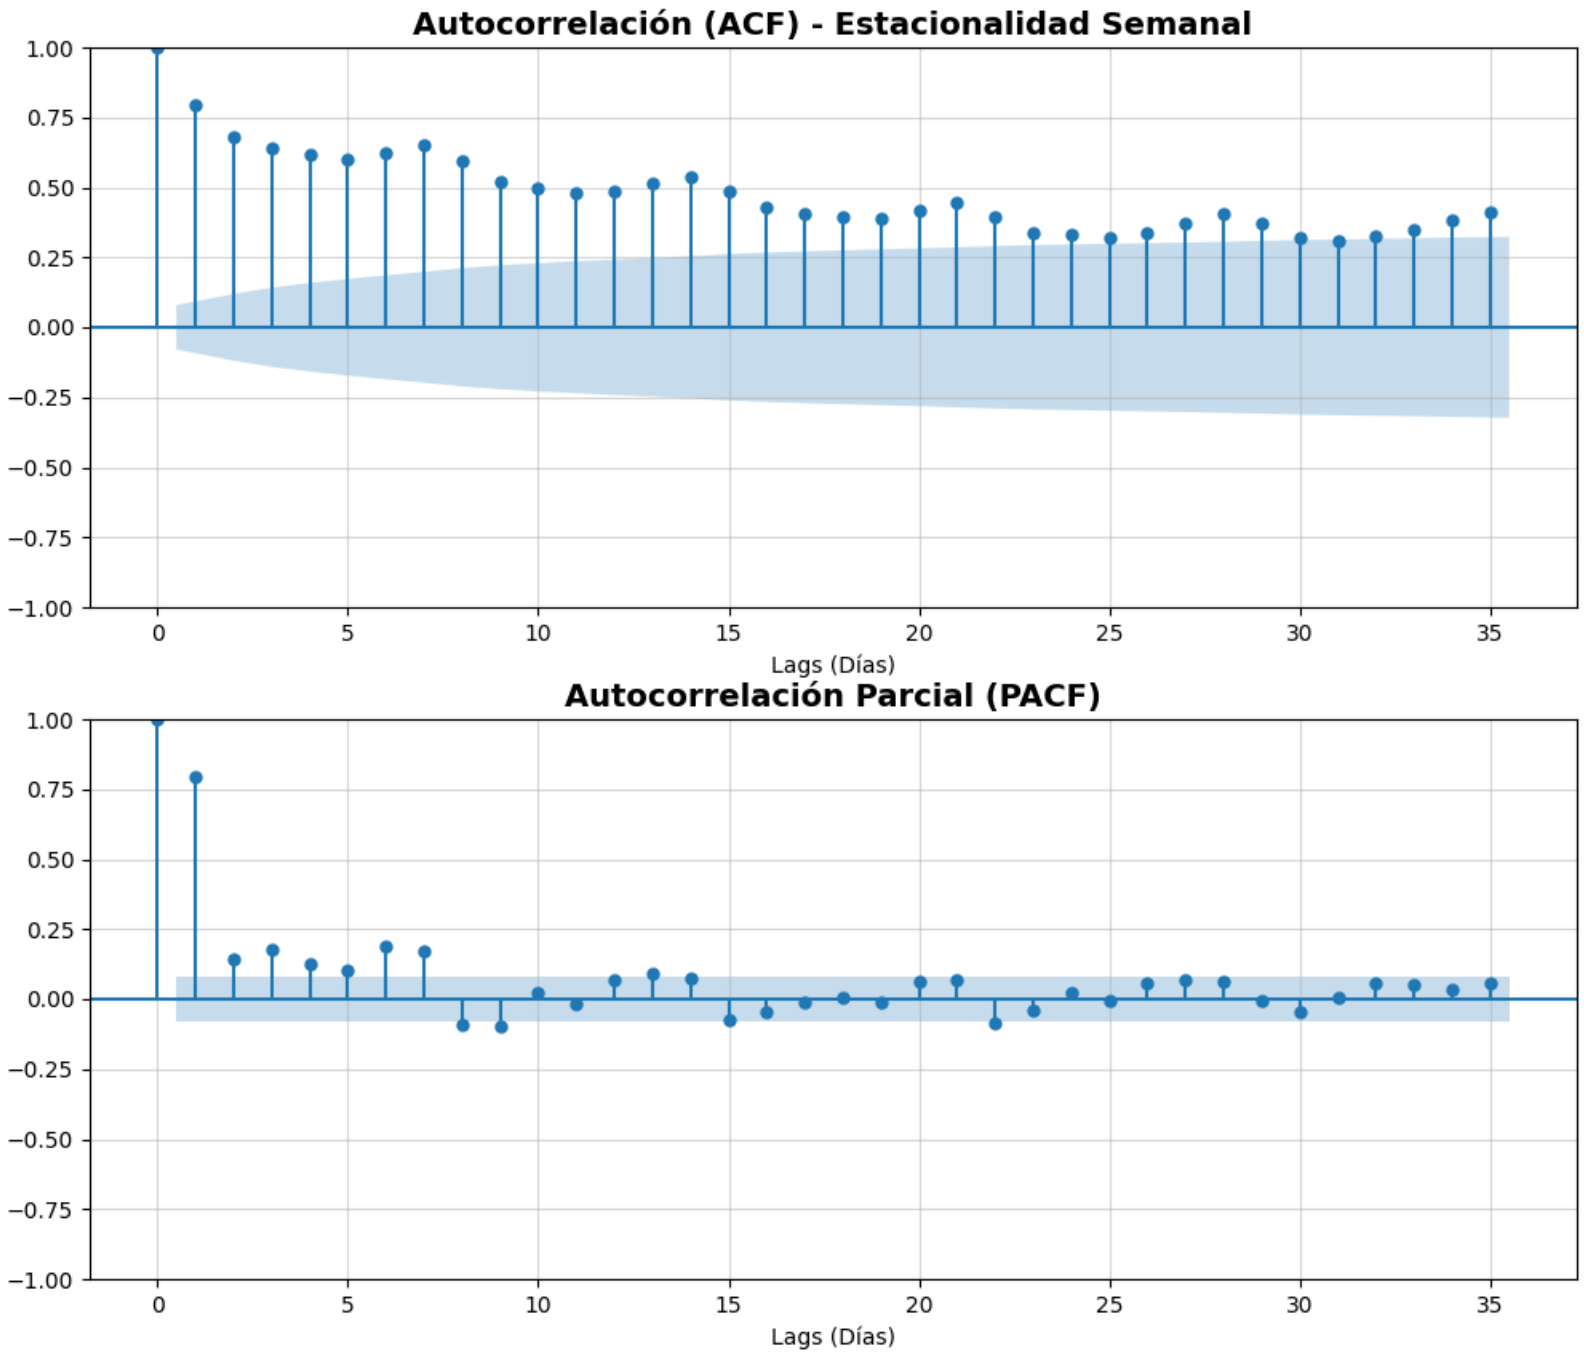

Figura 7: Funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) para detectar la ciclicidad semanal.

Los resultados mostrados en las gráficas de la Fig. (7) confirman que el ciclo semanal no es una simple sospecha, sino que es un patrón estructural dentro de los registros de los

pedidos en la empresa. En la primera (ACF) se observa que cada 7 días hay un "pico", correspondiente a una semana, lo cual da soporte estadístico a la estacionalidad identificada previamente (los Lunes y Martes son los días de mayor recepción de pedidos).

Por otra parte, la PACF sugiere que la influencia directa de días previos sobre la demanda actual es significativa principalmente hasta un día anterior, mientras que el resto de los rezagos no presentan una contribución estructural dominante.

2.8. Estacionalidad mensual

De manera análoga a como se ha hecho para encontrar un patrón recurrente semanalmente, el análisis mensual puede visualizarse en la Fig. (8).

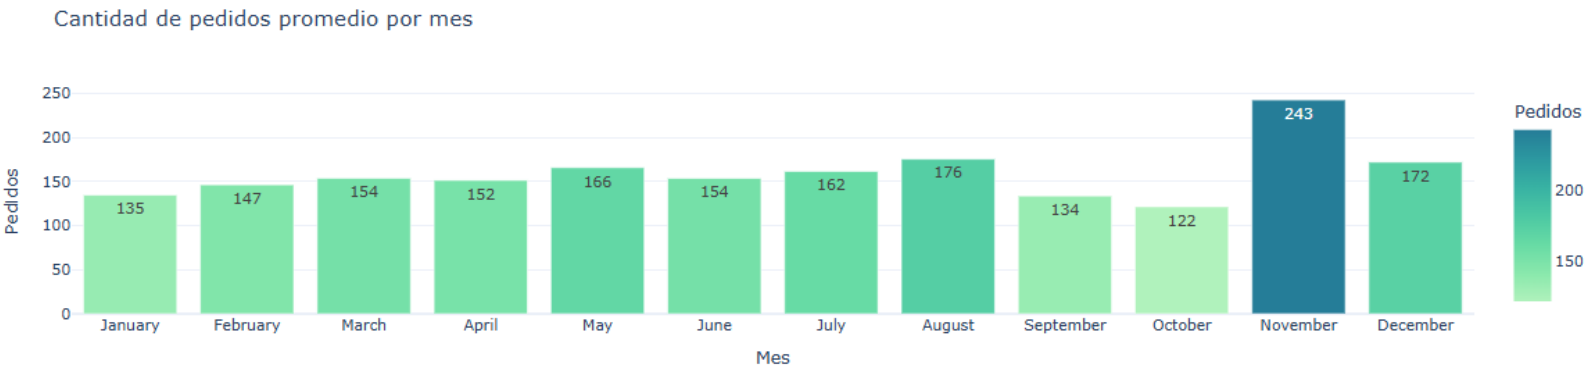

Figura 8: Cantidad promedio de pedidos realizados por mes del año.

Este gráfico muestra el impacto que tiene la baja densidad de datos en los meses de Septiembre y Octubre, ya que, en comparación con meses como Marzo o Abril que si tienen registros en, por lo menos, dos años, estos carecen de representatividad de varios años, contando únicamente con registros del ciclo 2017, lo que vuelve la comparación "injusta".

Por otra parte, también se nota el impacto que tiene el *Black Friday* en la cantidad de pedidos del mes de Noviembre.

Finalmente, en los meses correspondientes al primer trimestre, puede notarse un incremento paulatino en los pedidos. No obstante, no puede asegurarse que esto se deba al fenómeno conocido como "cuesta de Enero", posterior a grandes gastos que suele hacer la gente durante épocas decembrinas, sino que podría deberse a que precisamente estos meses están contenidos en los primeros registros que se tienen y coincide con la fase de inserción al mercado y escalamiento inicial de Olist, por lo que inicialmente la cantidad de pedidos era menor comparada con fechas más recientes (la tendencia ha sido alcista a lo largo del tiempo). Esta respuesta únicamente podría darse teniendo una mayor cantidad de registros anuales.

3 Conclusiones de la Fase I

Las conclusiones y hallazgos para esta primera parte del proyecto son:

- **Crecimiento Orgánico con Volatilidad Controlada:** Existe una tendencia alcista robusta en los ingresos diarios. Aunque el "ruido" es alto, las medias móviles de 7 y 30 días confirman una aceleración del negocio a partir de 2017.
- **Validación Estadística:** La correlación de Spearman de 0.96 confirma una correlación casi lineal entre volumen de pedidos e ingresos, validando que cualquier modelo que prediga correctamente la cantidad de pedidos será un predictor fiel de los ingresos futuros.
- **Estabilidad del Ticket Promedio ($137.04):** Se determinó que el aumento de ingresos no se debe a un incremento en precios o venta de productos de lujo, sino a un aumento en el volumen de operaciones. El ticket promedio es notablemente estable, lo que facilita el pronóstico basado en conteo de pedidos.
- **Ausencia de Datos:** Se detectaron periodos con ausencia de datos históricos en
  - **Septiembe 2016:** El único registro es del día 15 de Septiembre.
  - **Octubre 2016:** Solamente se tienen registros desde el día 3 hasta el 10 de Octubre.
  - **Diciembre 2016:** Se tiene únicamente un registro, el del día 23 de Diciembre.
- **Tasa de Éxito de Entregas:** La tasa de éxito en las entregas es de 97.02 %, mientras que las cancelaciones representan el 0.63 % de los pedidos totales.
- **Ciclo Operativo Semanal:** Se confirmó una estacionalidad estadística con un ciclo de 7 días. El pico máximo de actividad ocurre los Lunes y Martes, mientras que los Sábados presentan una reducción operativa del 32 % respecto al pico. Esto sugiere una reconfiguración de la carga logística, priorizando la capacidad de procesamiento a inicios de semana para evitar cuellos de botella.
- **Ciclo Operativo Mensual:** A pesar de la baja densidad de datos que se tiene como para poder hacer conclusiones certeras con respecto a una estacionalidad mensual, todo apunta a que días de ventas masivas (como el *Black Friday*) realmente tienen un gran impacto en la cantidad de pedidos y, por lo tanto, de los ingresos mensuales. Por otra parte, no puede asegurarse que la cantidad menor de pedidos durante el primer trimestre se deba a la *cuesta de Enero* o a su coincidencia con el inicio de registros de Olist. Para dar alguna conclusión es necesario tener una mayor cantidad de registros anuales.